

1. หน้าที่ของ Name Node, Data Node, Node Manager, Resource Manager

Name Node:

- เป็นหัวใจหลักของ Hadoop Distributed File System (HDFS)
- เก็บข้อมูลเกี่ยวกับโครงสร้างของไฟล์และโพลเดอร์ในระบบไฟล์
- จัดการการเข้าถึงไฟล์และโพลเดอร์
- ควบคุมการสร้าง, ลบ, และย้ายไฟล์หรือโพลเดอร์
- ไม่เก็บข้อมูลจริง (data blocks) แต่เก็บข้อมูลเมตา (metadata) เช่น ชื่อไฟล์, ขนาดไฟล์, ที่ตั้งของ data blocks

Data Node:

- เป็นโหนดที่เก็บข้อมูลจริงใน HDFS
- จัดการการอ่าน/เขียนข้อมูลจาก/ไปยังฮาร์ดดิสก์ในโหนดนั้น
- รายงานสถานะของ data blocks ให้ Name Node ทราบเป็นประจำ
- การเสียหายของ Data Node ไม่ส่งผลกระทบต่อระบบ เนื่องจากข้อมูลถูกกระจายเก็บในหลายโหนด

Node Manager:

- ส่วนหนึ่งของ Hadoop YARN (Yet Another Resource Negotiator)
- จัดการและตรวจสอบคอนเทนเนอร์ (containers) ในโหนดนั้น
- ควบคุมทรัพยากร (เช่น CPU, หน่วยความจำ) ที่ใช้ในคอนเทนเนอร์
- รายงานสถานะและทรัพยากรที่ใช้ไปยัง Resource Manager

Resource Manager:

- เป็นหัวใจหลักของ YARN
- จัดการทรัพยากรทั่วระบบคลัสเตอร์
- จัดการการจัดสรรทรัพยากรให้กับแอปพลิเคชันต่างๆ

- มีสองส่วนหลักคือ **Scheduler** (จัดการการจัดสรรทรัพยากรแบบรวมดา) และ **Application Manager** (จัดการแอปพลิเคชันในคลัสเตอร์)

2. วิธีเก็บข้อมูลและ operation

Spark vs Spark SQL:

- Spark:

- เป็นกรอบงานประมวลผลข้อมูลขนาดใหญ่แบบคลัสเตอร์
- รองรับการประมวลผลข้อมูลแบบ **batch** และ **real-time**
- ใช้ **RDD (Resilient Distributed Datasets)** สำหรับการประมวลผลข้อมูล
- รองรับการเขียนโค้ดด้วยหลายภาษา เช่น **Scala, Java, Python, และ R**

- Spark SQL:

- เป็นส่วนเสริมของ Spark ที่ให้ความสามารถในการทำงานกับข้อมูลเชิงโครงสร้าง
- ใช้ **DataFrame** และ **DataSet API** สำหรับการจัดการและประมวลผลข้อมูล
- รองรับการเขียนคำสั่ง **SQL** เพื่อการประมวลผลข้อมูล
- มีประสิทธิภาพสูงในการทำงานกับข้อมูลเชิงโครงสร้าง เช่น การกรอง, การรวม, และการจัดการข้อมูล

Hive vs HBase:

- Hive:

- เป็น **data warehouse software** ที่สร้างขึ้นบน **HDFS**
- ใช้ภาษา **SQL (HiveQL)** สำหรับการสืบค้นข้อมูล
- เหมาะสำหรับการประมวลผลข้อมูลแบบ **batch** และ **analytics**
- รองรับการเก็บข้อมูลในรูปแบบตาราง (**table-based storage**)

- HBase:

- เป็น distributed, scalable, NoSQL database ที่สร้างขึ้นบน HDFS
- เหมาะสำหรับการเก็บและจัดการข้อมูลขนาดใหญ่แบบเรียลไทม์
- เก็บข้อมูลในรูปแบบของ key-value pairs
- รองรับการอ่านและเขียนข้อมูลอย่างรวดเร็วและมีประสิทธิภาพ

3. ความแตกต่างของการนำเข้าข้อมูล: Sqoop, Flume, Kafka

Sqoop:

- ใช้สำหรับการโอนย้ายข้อมูลระหว่างระบบเก็บข้อมูลแบบ relational databases (เช่น MySQL, PostgreSQL) กับ Hadoop
- รองรับการนำเข้าข้อมูลจากฐานข้อมูลไปยัง HDFS, Hive, HBase และส่งออกข้อมูลจาก Hadoop ไปยังฐานข้อมูล
- ใช้คำสั่ง SQL เพื่อเลือกข้อมูลที่จะโอนย้าย

Flume:

- ออกแบบสำหรับการเก็บรวบรวม, รวม, และเคลื่อนย้ายข้อมูล log จากแหล่งข้อมูลต่างๆ ไปยัง HDFS
- รองรับการจัดการกับข้อมูลที่มาจากหลายแหล่งพร้อมกันและส่งข้อมูลไปยังหลายปลายทาง
- ใช้การออกแบบที่ปรับขนาดได้ง่ายและทนทานต่อข้อผิดพลาด

Kafka:

- เป็นระบบ distributed streaming platform ที่ใช้สำหรับการจัดการการสตรีมข้อมูลขนาดใหญ่แบบเรียลไทม์
- รองรับการ publish และ subscribe ข้อความ (messages) จากแหล่งข้อมูลต่างๆ
- ใช้สำหรับการจัดเก็บและการประมวลผลข้อมูลที่ส่งผ่านสตรีมแบบต่อเนื่อง
- เหมาะสำหรับการประมวลผลข้อมูลแบบเรียลไทม์และการส่งข้อมูลไปยังหลายปลายทางพร้อมกัน