

1. TPE (Take Performance Experience) ใน Machine Learning คืออะไร

TPE (Take Performance Experience):

- **ความหมาย:** TPE เป็นกลยุทธ์ที่เน้นการใช้ประสบการณ์และข้อมูลที่ได้จากการประมวลผลเพื่อปรับปรุงประสิทธิภาพของโมเดล Machine Learning
- **การใช้งาน:** ใช้ในการปรับพารามิเตอร์ของโมเดล (Hyperparameter tuning) โดยการประเมินผลของพารามิเตอร์ต่างๆ ผ่านการทดลองและประสบการณ์ที่สะสมมา
- **กระบวนการ:**
 1. **ตั้งค่าพารามิเตอร์เริ่มต้น:** เริ่มต้นด้วยการตั้งค่าพารามิเตอร์ที่คาดว่าจะได้ผลดีที่สุด
 2. **ประเมินผล:** รันโมเดลด้วยพารามิเตอร์ที่ตั้งค่าไว้และบันทึกผลลัพธ์
 3. **ปรับปรุงพารามิเตอร์:** ปรับพารามิเตอร์ตามผลลัพธ์ที่ได้และประสบการณ์ที่ผ่านมา
 4. **ทำซ้ำ:** ทำขั้นตอนนี้อีกจนกว่าจะได้พารามิเตอร์ที่เหมาะสมที่สุด

2. Regression / Classification: ยกตัวอย่าง Algorithm บอก Cost Function และ Evaluation Metrics

Regression:

- Linear Regression:

- **Algorithm:** สร้างเส้นตรงที่มีความเหมาะสมที่สุดในการพยากรณ์ค่าผลลัพธ์ (output) จากค่าตัวแปรอิสระ (input)
- **Cost Function:** Mean Squared Error (MSE)

$$MSE = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2$$

- Evaluation Metrics:

- Mean Absolute Error (MAE)
- Root Mean Squared Error (RMSE)
- R-squared (R^2)

Classification:

- Logistic Regression:

- **Algorithm:** ใช้สมการ logistic function ในการประมาณความน่าจะเป็นของการเกิดของเหตุการณ์ที่สนใจ

- **Cost Function:** Binary Cross-Entropy (Log Loss)

$$\text{Log Loss} = -\frac{1}{n} \sum_{i=1}^n [y_i \log(\hat{y}_i) + (1 - y_i) \log(1 - \hat{y}_i)]$$

- Evaluation Metrics:

- Accuracy

- Precision

- Recall

- F1 Score

- ROC-AUC

3. Ridge & Lasso

Ridge Regression:

- ความหมาย: เทคนิค Regularization ที่เพิ่ม penalty ของขนาดของค่าสัมประสิทธิ์ (coefficients) ของโมเดลเข้าไปใน cost function

- Cost Function:

$$J(\theta) = \text{MSE} + \lambda \sum_{j=1}^p \theta_j^2$$

- คุณสมบัติ: ช่วยลดการ overfitting โดยการบีบค่าสัมประสิทธิ์ให้เล็กลง

Lasso Regression:

- ความหมาย: เทคนิค Regularization ที่เพิ่ม penalty ของค่าสัมประสิทธิ์ของโมเดลเข้าไปใน cost function โดยใช้ค่า absolute value

- Cost Function:

$$J(\theta) = \text{MSE} + \lambda \sum_{j=1}^p |\theta_j|$$

- **คุณสมบัติ:** ช่วยลดการ overfitting และสามารถทำให้ค่าสัมประสิทธิ์บางตัวเป็นศูนย์ได้ ซึ่งช่วยในการเลือกตัวแปร (feature selection)

4. K-means & K-NN

K-means Clustering:

- **ความหมาย:** อัลกอริธึมการจัดกลุ่ม (clustering) ที่แบ่งข้อมูลออกเป็น k กลุ่ม โดยให้แต่ละกลุ่มมีจุดศูนย์กลาง (centroid) ที่เหมาะสมที่สุด

- **กระบวนการ:**

1. กำหนดจำนวนกลุ่ม k
2. สุ่มเลือกจุดศูนย์กลางเริ่มต้น k จุด
3. จัดกลุ่มข้อมูลแต่ละจุดไปยังจุดศูนย์กลางที่ใกล้ที่สุด
4. อัปเดตจุดศูนย์กลางใหม่โดยการคำนวณค่าเฉลี่ยของจุดในแต่ละกลุ่ม
5. ทำซ้ำขั้นตอนที่ 3-4 จนกว่าจุดศูนย์กลางจะไม่เปลี่ยนแปลง

- **Evaluation Metrics:**

- Within-cluster Sum of Squares (WCSS)
- Silhouette Score

K-Nearest Neighbors (K-NN):

- **ความหมาย:** อัลกอริธึมการจำแนกประเภท (classification) ที่ใช้ความคล้ายคลึงกันของข้อมูลในการจำแนก

- **กระบวนการ:**

1. กำหนดจำนวนเพื่อนบ้าน k
2. คำนวณระยะห่างระหว่างจุดที่ต้องการจำแนกกับทุกจุดในข้อมูลฝึก
3. เลือก k จุดที่ใกล้ที่สุด
4. ให้ค่าที่พบมากที่สุดใน k จุดเป็นคำตอบ

- Evaluation Metrics:

- Accuracy
- Precision
- Recall
- F1 Score

5. การใช้ Logistic Regression กับการจำแนกรูปแมว

การใช้ **Logistic Regression** ในการจำแนกรูปแมว:

- ขั้นตอน:

1. **รวบรวมข้อมูล:** รวบรวมรูปภาพแมวและไม่ใช่แมวในรูปแบบที่สามารถใช้งานได้ (เช่น รูปแบบ digital image)
2. **เตรียมข้อมูล:**
 - แปลงรูปภาพเป็นตัวเลข (เช่น การใช้ค่าพิกเซล)
 - ปรับขนาดรูปภาพให้เท่ากัน
 - แบ่งข้อมูลเป็นชุดฝึกและชุดทดสอบ
3. **สร้าง Label:** กำหนด label สำหรับรูปแมวเป็น 1 และรูปอื่นเป็น 0
4. **สร้างโมเดล Logistic Regression:**
 - ใช้ Logistic Regression ในการสร้างโมเดล
 - ฟังก์ชัน sigmoid เพื่อประมาณค่าความน่าจะเป็นของการเป็นรูปแมว
5. **ฝึกโมเดล:** ใช้ข้อมูลชุดฝึกในการฝึกโมเดล
6. **ทดสอบโมเดล:** ใช้ข้อมูลชุดทดสอบในการประเมินประสิทธิภาพของโมเดล
7. **ปรับปรุงโมเดล:** ทำการปรับแต่งพารามิเตอร์หากจำเป็น

- Cost Function:

$$\text{Log Loss} = -\frac{1}{n} \sum_{i=1}^n [y_i \log(\hat{y}_i) + (1 - y_i) \log(1 - \hat{y}_i)]$$

- **Evaluation Metrics:**

- Accuracy
- Precision
- Recall
- F1 Score
- ROC-AUC