

1. (15 คะแนน) จงเขียนชุดคำสั่งของ PySpark ที่สร้าง RDD จาก List ของ Key Value Pairs ต่อไปนี้

$D = [(1,4), (0, 9), (-2,5), (5,1), (-4, 9), (1,9), (1, 3)]$

จากนั้นให้คัดเลือกเฉพาะ Key value pair ที่มีค่า Key เป็นบวก แล้วทำการ Group by key ผลลัพธ์ และหาค่าเฉลี่ยของ Values ในแต่ละ Key

2. (15 คะแนน) จงอธิบายคุณสมบัติต่อไปนี้ของ Spark

2.1 Distributed and Memory Processing

2.2 Fault Tolerant Computing


3. (15 คะแนน) จงทำโจทย์ข้อ 1 แต่ใช้ Data frame ในการจัดเก็บ Key Value Pairs

4. (10 คะแนน) จงอธิบายหลักการ Pipeline ของ ML พร้อมอธิบายหน้าที่และการทำงานของ Transformer และ Estimator

5. (10 คะแนน) จงอธิบายจุดประสงค์และวิธีการทำ Collaborative Filtering ด้วยเทคนิค ALS

6. (10 คะแนน) จงอธิบายขั้นตอนการและวิธีการแปลงข้อความ (Text) จนเป็น Feature Vector เพื่อสามารถนำไปใช้ในการเรียนรู้ได้

7. (15 คะแนน) จากกราฟที่กำหนดให้ข้างล่าง



7.1 เขียนชุดคำสั่งในการสร้างกราฟที่กำหนดให้ ( จาก List ของ Edges และ Vertices )

7.2 จากกราฟที่ได้สร้างแล้วในข้อ 7.1 ให้เขียนคำสั่งในการสร้าง Subgraph ที่มี Vertices คงเดิม แต่มี Edges ที่มีค่า Property Value เป็นบวกเท่านั้น

8. (10 คะแนน) จงอธิบายวิธีการทำงานของ Pregel และวิธีการใช้ Pregel ทำ Page Ranking มาให้เข้าใจ